Universidade Federal do Amazonas
Departamento de Estatística

Curso: Introdução à Ciência de Dados
Professor: Leonardo Nascimento
12/12/2023
Versão 1.0

- No contexto da linguagem de programação R, objetos e vetores são conceitos fundamentais relacionados à manipulação de dados;

1 Objetos

- Um objeto é simplesmente um **nome** que guarda um valor;
- O R permite salvar valores dentro de um **objeto**
- Para criar um objeto, escolha um **nome** e use `<-` ou `=` para guardar a informação dentro do objeto
- Considere os exemplos abaixo

```r
a <- 2
a = 2
print(a)
#> [1] 2
```

```r
b <- 1:6
print(b)
#> [1] 1 2 3 4 5 6
```

- Observação: quando o objeto for criado, ele aparecerá no painel *Environment*
- Ao escolher nomes para objetos em R, é importante seguir algumas regras e boas práticas para garantir a clareza, consistência e evitar conflitos com palavras reservadas.
- Aqui estão algumas restrições para nomear objetos em R:
    - **Sintaxe básica:**
        - Os nomes de objetos devem começar com uma letra.
        - Podem conter letras, números e pontos (.), mas **não podem começar com um número ou conter espaços**.
        - Evite o uso de caracteres especiais, como @, $, %, &, etc.
    - **Palavras reservadas:**
        - Evite usar nomes que são palavras reservadas em R, pois isso pode causar conflitos. Alguns exemplos de palavras reservadas incluem `if`, `else`, `while`, `function`, `for`, `in`, `TRUE`, `FALSE`, entre outras.
    - **Observação**:
        - O R **diferencia letras maiúsculas e minúsculas**, isto é, `a` é considerado um objeto diferente de `A`
        - Escolha nomes descritivos que forneçam informações sobre o propósito ou conteúdo do objeto.
        - No R, uma base de dados é representada por objetos chamados de *data frames*
        - Exemplos de nomes aceitáveis: `idade`, `nomeVariavel`, `meuVetor`, `resultado_final` e `dados_do_paciente`

2 Vetores

- Um vetor é uma estrutura de dados unidimensional que pode conter ou não elementos de um único tipo
- Os vetores podem ser subdivididos em : **vetores atômicos** e **listas**
- Eles diferem quanto aos tipos de seus elementos:
    - para **vetores atômicos**, todos os elementos devem ter o mesmo tipo;
    - **para listas**, os elementos podem ter tipos diferentes.
- Os elementos de um vetor são acessados por índices.

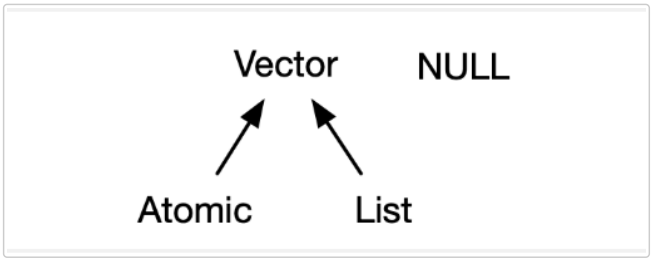

2.1 Vetores atômicos

- Existem quatro tipos principais de vetores atômicos: lógico, inteiro, *double* e caractere (que contém strings);
- Vetores inteiros e *double* são conhecidos como vetores numéricos;
- Para criar vetores use a função `c()` (*combine*)
- Para saber o tipo de vetor, você pode utilizar a funcão `typeof()`. Para saber seu comprimento a função `length()`.
- Você pode **testar** se um vetor é de um determinado tipo com uma função `is.*()`

2.1.1 Lógico

```
lgl_var <- c(TRUE, FALSE)# lógico
lgl_var <- c(T, F)# lógico
typeof(lgl_var)# verificar o tipo
#> [1] "logical"
is.logical(lgl_var) # testar se o vetor é do tipo lógico
#> [1] TRUE
is.integer(lgl_var)
#> [1] FALSE
length(lgl_var)
#> [1] 2
```

2.1.2 Double

```
dbl_var <- c(1, 2.5, 4.5)#forma decimal
dbl_var <- c(1.23e4)##forma científica
typeof(dbl_var)
#> [1] "double"
is.double(dbl_var) # testar se o vetor é do tipo Double
#> [1] TRUE
is.character(lgl_var)
#> [1] FALSE
```

```r
length(dbl_var)
#> [1] 1
```

- Existem três valores especiais exclusivos para Double: Inf, -Inf e NaN (Not a Number)

```r
dbl_var <- c(Inf,-Inf,NaN)
typeof(dbl_var)
#> [1] "double"
```

2.1.3 Inteiro

- Os inteiros são escritos de forma semelhante aos Double, mas devem ser seguidos por L

```r
int_var <- c(1L, 6L, 10L)# inteiro
typeof(int_var)
#> [1] "integer"
is.integer(int_var)
#> [1] TRUE
is.character(int_var)
#> [1] FALSE
length(int_var)
#> [1] 3
```

2.1.4 Caractere (string)

- As strings são colocados entre " "

```r
chr_var <- c("Leonardo", "Nascimento")
chr_var <- c("Ótimo", "Bom","Ruim")
chr_var <- c("Masculino", "Feminino")
is.character(chr_var)
#> [1] TRUE
typeof(chr_var)
#> [1] "character"
```

2.1.5 Observações

- Em um vetor, cada valor ocupa uma posição específica determinada pela ordem em que os elementos foram adicionados durante a criação do vetor.
- Essa ordem é crucial para acessar cada valor de maneira individual dentro do vetor.

```r
meu_vetor = c(1,2,10,4,5)
meu_vetor[3]
#> [1] 10
```

2.1.5.1 NULL

- Embora não seja um vetor, `NULL`está intimamente relacionado aos vetores e geralmente desempenha a função de um vetor genérico de comprimento zero.

```
vetor_null <- c(NULL)
vetor_null
#> NULL
typeof(vetor_null)
#> [1] "NULL"
```

2.1.5.2 NA

- Em R, “NA” (*Not Available*) é usado para representar valores ausentes ou desconhecidos.
- A maioria dos cálculos envolvendo um valor faltante retornará outro valor faltante.

```
meu_vetor <- c(10,NA)
2*meu_vetor
#> [1] 20 NA
```

- Para verificar se um valor é “NA”, você pode usar a função `is.na()`.

```
x <- c(1, 2,3,NA, 5)
is.na(x)
#> [1] FALSE FALSE FALSE  TRUE FALSE
```

- Muitas funções em R têm maneiras para lidar com valores ausentes. Por exemplo, algumas funções têm argumentos como `na.rm` para remover NAs durante cálculos

```
notas_alunos <- c(10, 7, NA, 8, 8.5)
mean(notas_alunos, na.rm = TRUE) # média
#> [1] 8.375
```

- Você pode substituir valores NA por outros valores usando a função `is.na()` e indexação

```
meu_vetor <- c(1, 2,3, 4, NA)
meu_vetor[is.na(meu_vetor)] <- 0
```

2.1.6 Coerção

- Para vetores atômicos, o tipo é uma propriedade de todo o vetor
- Todos os elementos devem ser do mesmo tipo.
- Quando você tenta combinar tipos diferentes, eles serão forçados em uma ordem fixa: caractere → double → inteiro → lógico.

```r
y1 <- c(1L,"leonardo") # inteiro, character
y1
#> [1] "1"        "leonardo"
typeof(y1)
#> [1] "character"

y2 <- c(5.5,10L) # double, inteiro
y2
#> [1]  5.5 10.0
typeof(y2)
#> [1] "double"
```

2.2 Listas

- As listas são um avanço em complexidade em relação aos vetores atômicos: cada elemento pode ser de qualquer tipo
- Você constrói listas com a função `list()`

```r
l1 <- list(
  1:3,
  "a",
  c(TRUE, FALSE, TRUE),
  c(2.3, 5.9)
)
print(l1)
#> [[1]]
#> [1] 1 2 3
#>
#> [[2]]
#> [1] "a"
#>
#> [[3]]
#> [1]  TRUE FALSE  TRUE
#>
#> [[4]]
#> [1] 2.3 5.9
typeof(l1)
#> [1] "list"
```

- Para acessa um elemento da lista usamos `[[ ]]`

```r
l1 <- list(
  1:3,
  "a",
  c(TRUE, FALSE, TRUE),
  c(2.3, 5.9)
)
```

```
l1[[4]]
#> [1] 2.3 5.9
l1[[4]][1]
#> [1] 2.3
```

- Você pode testar uma lista com `is.list()` e forçar uma lista com `as.list()`

```
minha_lista = list(1:3)
print(minha_lista)
#> [[1]]
#> [1] 1 2 3
is.list(minha_lista)
#> [1] TRUE
vec <- c(1,2,3)
is.list(vec)
#> [1] FALSE
as.list(vec)
#> [[1]]
#> [1] 1
#>
#> [[2]]
#> [1] 2
#>
#> [[3]]
#> [1] 3
```

Você pode transformar uma lista em um vetor atômico com `unlist()`.

```
minha_lista = list(1:3,4:10)
print(minha_lista)
#> [[1]]
#> [1] 1 2 3
#>
#> [[2]]
#> [1]  4  5  6  7  8  9 10
unlist(minha_lista)
#>  [1]  1  2  3  4  5  6  7  8  9 10
```

- As regras para o tipo resultante são complexas, não estão bem documentadas e nem sempre são equivalentes ao que você obteria com `c()`.

3 Matrizes

- Uma matriz em R é uma estrutura bidimensional que pode armazenar dados de um único tipo.
- Isso significa que todos os elementos de uma matriz devem ser do mesmo tipo, como números inteiros, *double* ou caracteres.

- Você pode criar uma matriz usando a função `matrix()`. Especifique os dados e o número de linhas e colunas.

```
# Criando uma matriz 2x2
vec1 = c(1,2)
vec2 = c(3,4)
minha_matriz <- matrix(c(vec1,vec2), nrow = 2, ncol = 2)
minha_matriz
#>      [,1] [,2]
#> [1,]    1    3
#> [2,]    2    4
is.matrix(minha_matriz)
#> [1] TRUE
```

```
vec1 = c(1,2)
vec2 = c(3,4)
minha_matriz <- matrix(c(vec1,vec2), nrow = 2, ncol = 2,byrow = T)
minha_matriz
#>      [,1] [,2]
#> [1,]    1    2
#> [2,]    3    4
dim(minha_matriz)
#> [1] 2 2
ncol(minha_matriz)
#> [1] 2
nrow(minha_matriz)
#> [1] 2
```

- Os elementos de uma matriz podem ser acessados usando índices de linha e coluna.

```
minha_matriz[1,2] # Acessando o elemento na primeira linha e segunda coluna
#> [1] 2
```

4 Array

- Um array em R é uma estrutura de dados multidimensional que pode conter elementos de um único tipo. Diferentemente das matrizes, os arrays podem ter mais de duas dimensões.
- Você pode criar um array usando a função `array()`. Especifique os dados e as dimensões.

```
# Criando um array 2x3x2 - linhas X colunas X camadas
vec1 = c(1L,2L,3L,4L)
vec2 = c(5L,6L,7L,8L)
vec2 = c(5L,6L,7L,8L)
meu_array <- array(c(vec1,vec2), dim = c(2,2,3))
meu_array
#> , , 1
#>
```

```
#>      [,1] [,2]
#> [1,]    1    3
#> [2,]    2    4
#>
#> , , 2
#>
#>      [,1] [,2]
#> [1,]    5    7
#> [2,]    6    8
#>
#> , , 3
#>
#>      [,1] [,2]
#> [1,]    1    3
#> [2,]    2    4
typeof(meu_array)
#> [1] "integer"
```

- Os elementos de um array são acessados usando índices correspondentes às dimensões.

```
meu_array[1,2,2]# linhas X colunas X camadas
#> [1] 7
meu_array[,,1] # acessando a matriz da primeira camada
#>      [,1] [,2]
#> [1,]    1    3
#> [2,]    2    4
meu_array[,,2]# acessando a matriz da segunda camada
#>      [,1] [,2]
#> [1,]    5    7
#> [2,]    6    8
```

5 Data frame

- No R, um data frame é uma estrutura de dados bidimensional semelhante a uma tabela em um banco de dados relacional ou a uma planilha.
- Cada coluna em um data frame pode conter dados de diferentes tipos, tornando-os especialmente úteis para representar conjuntos de dados complexos.
- Você pode criar um data frame manualmente usando a função `data.frame()`.

```
meu_data_frame <- data.frame(
  Nome = c("Alice","Leo","Vitor"),
  Idade = c(25,30,22),
  Nota = c(85, 92, 78)
)
meu_data_frame
#>    Nome Idade Nota
#> 1 Alice    25   85
```

```
#> 2   Leo    30   92
#> 3 Vitor    22   78
```

```
dados_climaticos <- data.frame(
  Dia = seq(from = as.Date("2023-01-01"), by = "days", length.out = 5),
  Temperatura = c(25.3, 24.5, 22.0, 26.8, 23.5),
  Umidade = c(65, 70, 75, 60, 80),
  VelocidadeVento = c(10, 12, 8, 15, 9)
)

# Exibindo o data frame
print(dados_climaticos)
#>          Dia Temperatura Umidade VelocidadeVento
#> 1 2023-01-01        25.3      65              10
#> 2 2023-01-02        24.5      70              12
#> 3 2023-01-03        22.0      75               8
#> 4 2023-01-04        26.8      60              15
#> 5 2023-01-05        23.5      80               9
head(dados_climaticos,3)
#>          Dia Temperatura Umidade VelocidadeVento
#> 1 2023-01-01        25.3      65              10
#> 2 2023-01-02        24.5      70              12
#> 3 2023-01-03        22.0      75               8
```

- Você pode acessar uma coluna específica usando o nome da coluna.
- Você também pode acessar elementos por índices de linha e coluna

```
dados_climaticos$Temperatura
#> [1] 25.3 24.5 22.0 26.8 23.5
dados_climaticos[,2]
#> [1] 25.3 24.5 22.0 26.8 23.5
```

6 Atributos

- Além dos próprios elementos, os vetores podem ter atributos que fornecem informações adicionais sobre os dados

6.1 Nomes

- Você pode atribuir nomes a cada elemento do vetor usando a função `names()`. Isso facilita a referência a elementos específicos pelo nome.

```
meu_vetor <- c(1, 2, 3)
names(meu_vetor) <- c("primeiro", "segundo", "terceiro")
meu_vetor
#> primeiro  segundo terceiro
#>        1        2        3
attributes(meu_vetor)
#> $names
#> [1] "primeiro" "segundo"  "terceiro"
```

- Formas alternativas para nomear um vetor

```
x1 <- c(a = 1, b = 2, c = 3)
x1
#> a b c
#> 1 2 3

x2 <- setNames(1:3, c("a", "b", "c"))
x2
#> a b c
#> 1 2 3
```

6.2 Dimensão

- Em R, vetores podem ter atributos de dimensão, que são comumente associados a matrizes.

```
meu_vetor <- 1:5
meu_vetor
#> [1] 1 2 3 4 5
dim(meu_vetor) <- c(5, 1) # linha x coluna
meu_vetor
#>      [,1]
#> [1,]    1
#> [2,]    2
#> [3,]    3
#> [4,]    4
#> [5,]    5
attributes(meu_vetor)
#> $dim
#> [1] 5 1
```

6.3 Classe

- A classe de um objeto é uma propriedade que indica a natureza ou tipo do objeto em termos de programação orientada a objetos
- A classe é uma parte fundamental em R, pois determina como o objeto será tratado em operações específicas e quais métodos (funções associadas) podem ser aplicados a ele.
- Aqui estão algumas das classes mais comuns em R:
    - **numeric:** Números reais (*double*).
    - **integer:** Números inteiros.
    - **logical:** Valores lógicos (TRUE ou FALSE).
    - **character:** Strings de caracteres.
    - **factor:** Fatores, usados para representar variáveis categóricas com níveis
    - **Date:** Representação de datas.
    - **POSIXct e POSIXlt:** Representação de datas e horas.
    - **data.frame:** Uma estrutura bidimensional que pode conter colunas de diferentes classes.
    - **matrix:** Uma estrutura bidimensional que contém elementos de uma única classe.
    - **array:** Uma estrutura de dados multidimensional que pode conter elementos de uma única classe.
    - **list:** Uma estrutura que pode conter elementos de diferentes classes e até outras listas.
    - **function:** Funções.
- Em R, a função `class()` é usada para obter a classe de um objeto

```r
vec1 = c(1,2)
vec2 = c(3,4)
class(vec1)
#> [1] "numeric"
minha_matriz <- matrix(c(vec1,vec2), nrow = 2, ncol = 2)
minha_matriz
#>      [,1] [,2]
#> [1,]    1    3
#> [2,]    2    4
class(minha_matriz)
#> [1] "matrix" "array"
```

- Você pode atribuir uma classe a um vetor usando a função `class()`. Isso é comumente usado em programação orientada a objetos em R.

```r
vec <- c(1,2,3,4)
class(vec)
#> [1] "numeric"
class(vec)<- "minha_classe"
class(vec)
#> [1] "minha_classe"
```

6.4 Exemplo

- Criando um objeto da classe Pessoa

```r
pessoa1 <- structure(
  c("Leonardo"),
  idade = 31,
  last_name = "Nascimento",
  class = "Pessoa",
  names = c("nome_pessoa")
)
pessoa1
#> nome_pessoa
#>   "Leonardo"
#> attr(,"idade")
#> [1] 31
#> attr(,"last_name")
#> [1] "Nascimento"
#> attr(,"class")
#> [1] "Pessoa"
class(pessoa1)
#> [1] "Pessoa"
attr(pessoa1,"idade") # selecionado o atributo idade
#> [1] 31
```

```r
names(pessoa1)
#> [1] "nome_pessoa"
```

7 Importação/Exportação de dados

- Em R, você pode usar várias funções para importar e exportar dados em diferentes formatos, incluindo CSV, TXT e RDS. Abaixo estão exemplos de como realizar essas operações.

7.1 .CSV

- Importação

```r
dados_sexo_curso <-
         read.csv("~/GitHub/Introducao_Ciencias_de_Dados/dados/tab_sexo_curso.csv")
head(dados_sexo_curso)
#>   sexo curso
#> 1  Mas   Fís
#> 2  Mas   Fís
#> 3  Mas   Fís
#> 4  Mas   Fís
#> 5  Mas   Fís
#> 6  Mas   Fís
```

- Exportação

```r
exemplo_csv = data.frame(Pessoa = c("Leo","Lennon"),Idade=c(30,29))
write.csv(exemplo_csv ,"~/GitHub/Introducao_Ciencias_de_Dados/dados/exemplo_csv.csv")
```

7.2 .TXT

- Importação

```r
dados_temperatura <-
         read.table("~/GitHub/Introducao_Ciencias_de_Dados/dados/temperatura.txt")
head(dados_temperatura)
#>   temperatura
#> 1      23.545
#> 2      26.878
#> 3      33.807
#> 4      26.860
#> 5      24.675
#> 6      27.256
```

- Exportação

```r
exemplo_txt = data.frame(Pessoa = c("Leo","Lennon"),Idade=c(30,29))
write.table(exemplo_txt ,"~/GitHub/Introducao_Ciencias_de_Dados/dados/exemplo_txt.txt")
```

7.3 .RDS

- Importação

```r
dados <- readRDS("~/GitHub/Introducao_Ciencias_de_Dados/dados/tempo_exercicio_perda_peso.rds")
head(dados)
#>   tempo_exercicio perda_peso
#> 1        3.696831   5.978045
#> 2        6.242891  10.833239
#> 3        7.764007  10.846056
#> 4        5.703023   8.170098
#> 5        3.695822   4.126396
#> 6        1.597858   3.247096
```

- Exportação

```r
exemplo_rds = data.frame(Pessoa = c("Leo","Lennon"),Idade=c(30,29))
saveRDS(exemplo_rds ,"~/GitHub/Introducao_Ciencias_de_Dados/dados/exemplo_rds.rds")
```

7.4 Observações

1. **Separadores e Delimitadores:**
   - Certifique-se de usar o argumento `sep` para especificar o separador ou delimitador correto, dependendo do formato do seu arquivo (vírgula, ponto e vírgula, tabulação, etc.).
2. **Encodings:**
   - Se você estiver trabalhando com arquivos que contêm caracteres especiais, pode ser necessário especificar o encoding usando o argumento `fileEncoding`.
3. **Cabeçalho:**
   - Utilize o argumento `header` para indicar se o arquivo contém um cabeçalho ou não (`header = TRUE` para sim, `header = FALSE` para não).
4. **Path:**
   - Se estiver usando caminhos no Windows, pode ser necessário usar barras invertidas duplas (\\) ou uma única barra invertida (\) para especificar o caminho.

8 Referências

- Advanced R
- R for Data Science

- Hands-On Programming with R